

张志强

✉ zhangzhiqiangcs@outlook.com · ☎ (+86) 131-2120-0924 · 🌐 zhangzhiqiangcs

教育经历

南开大学 软件学院/软件工程，本科 2012 – 2016
中科院计算所 计算机体系结构/区块链，硕士 2017 – 2020

工作经历

百度, 北京 软件工程师 2025 年 6 月 – 至今
百舸 AI 计算平台

- 负责托管资源池 **GPU 虚拟化与异构调度**能力建设，实现 MIG 队列创建、资源视图展示，支持 A100/A800 混合调度，提升异构算力利用率。
- 主导**队列资源视图存储与缓存架构优化**：开发 etcd-to-mysql 多集群资源实时同步系统，设计冷热存储分离架构与三级渐进式读取策略，实现调和控制器保障 MySQL 与 K8s 双写一致性；优化资源视图校准逻辑，排除系统预留和系统组件占用，准确展示节点/队列真实可用资源。
- 设计并实现**闲时任务**功能，支持队列闲时资源出借与闲时任务调度，通过 Volcano 调度器增强抢占和回收机制。
- 负责 **Volcano 调度器**组件维护，累计发布 10+ 版本，修复 panic、并发安全等关键问题，新增物理队列污点容忍等能力。

旷视, 北京 软件工程师 2020 年 6 月 – 2025 年 5 月
AI PaaS 平台

- 构建 AI PaaS 平台，集成算力、算法、智能体管理，基于 **vLLM** 优化大模型推理流程，提供 OpenAI API 兼容的推理服务。
- 支持多种智能体接入，实现会话管理、历史消息管理，适配 Kubernetes 实现推理任务弹性调度。

私有云平台 MDP

- 基于 Kubekey 设计 Kubernetes 交付方案，构建公司内部**软件发布中心**，集成镜像中心、监报告警、Helm Chart 交付等核心能力。
- 建设集群管理与业务 Dashboard，实现集群状态可视化、业务监控与运维诊断，支撑业务快速落地私有云架构。

私有云平台 DevOps

- 自研容器编排引擎与包管理器，包含命令行工具、制品仓库与控制器，实现 ToB 场景下的标准化交付与自动化运维。
- 基于 CodeMeter 设计产品授权机制，提供授权生成与验证能力，增强系统安全性与商业防护能力。

腾讯, 容器云开发组, 实习生, 北京 2019 年 6 月 – 2019 年 8 月

- 参与腾讯云容器存储（Ceph 集群）的开发和维护，优化存储服务的可靠性和性能。
- 排查线上 Ceph 集群异常问题，通过日志分析和 ceph status 监控诊断问题，修复存储节点异常问题，提高系统稳定性。

技能

- 精通 Golang，熟悉 Python，具备大型分布式系统的架构设计与开发经验。
- 深入研究 **AI Infra**：推理调度 (llm-d、GAIE、P/D 分离)、分布式训练 (NCCL、RDMA、DeepEP)、GPU 通信 (NVLink、拓扑优化)、云原生 (Kubernetes、Operator)。
- 熟悉 **GPU 虚拟化** (MIG、vGPU) 与异构混合调度，有生产环境落地经验。
- 熟练使用 Coding Agent 工具 (Claude Code) 提升研发效率，有 AI 辅助代码生成、文档撰写、问题排查的实践经验。