

张志强

✉ zhangzhiqiangcs@outlook.com · ☎ (+86) 131-2120-0924 · 🌐 zhangzhiqiangcs

教育经历

南开大学 软件学院/软件工程，本科 2012 – 2016
中科院计算所 计算机体系结构/区块链，硕士 2017 – 2020

工作经历

百度, 北京 软件工程师 2025 年 6 月 – 至今
百舸 AI 计算平台

- 负责托管资源池**队列能力建设**：设计**闲时任务**功能，支持队列空闲资源出借与多物理队列间闲时资源共享、抢占回收，提升集群资源利用率；设计**MIG 虚拟化**、**多芯异构混合调度**、**多套餐规格组方案**，实现 RDMA/eRDMA 默认使能属性，打破队列对 GPU 型号和规格的限制。
- 维护 **Volcano 调度器**，为队列配额调度、抢占回收等提供底层调度能力，累计发布 10+ 版本。
- 主导**队列资源视图优化**：引入最大可用量视图，排除系统预留和系统组件占用，准确展示节点/队列**真实可调度资源上限**；开发 etcd-to-mysql 后台汇聚系统，实时汇聚队列内所有节点资源视图并写入缓存，提升资源视图查询性能与实时性。
- 主导**推理公共资源池**技术方案设计：设计多租户共享集群与节点级隔离架构，实现算力单元规格售卖模型与按租户库存控制，完成整节点调度与调度隔离方案，构建可信推理服务的资源底座。

旷视, 北京 软件工程师 2020 年 6 月 – 2025 年 5 月
AI PaaS 平台

- 构建 AI PaaS 平台，集成算力、算法、智能体管理，基于 **vLLM** 优化大模型推理流程，提供 OpenAI API 兼容的推理服务。
- 支持多种智能体接入，实现会话管理、历史消息管理，适配 **Kubernetes** 实现推理任务弹性调度。

私有云平台 MDP

- 基于 Kubekey 设计 **Kubernetes** 交付方案，构建公司内部**软件发布中心**，集成镜像中心、监报告警、Helm Chart 交付等核心能力。
- 建设集群管理与业务 **Dashboard**，实现集群状态可视化、业务监控与运维诊断，支撑业务快速落地私有云架构。

私有云平台 DevOps

- 自研容器编排引擎与包管理器，包含命令行工具、制品仓库与控制器，实现 **ToB** 场景下的标准化交付与自动化运维。
- 基于 **CodeMeter** 设计产品授权机制，提供授权生成与验证能力，增强系统安全性与商业防护能力。

腾讯, 容器云开发组, 实习生, 北京 2019 年 6 月 – 2019 年 8 月

- 参与腾讯云容器存储（**Ceph 集群**）的开发和维护，优化存储服务的可靠性和性能。
- 排查线上 **Ceph 集群**异常问题，通过日志分析和 **ceph status** 监控诊断问题，修复存储节点异常问题，提高系统稳定性。

技能

- 精通 **Golang**，熟悉 **Python**，具备大型分布式系统的架构设计与开发经验。
- 深入研究 **AI Infra**：推理调度（**PD 分离**、**kvcache**、推理引擎）、分布式训练（**NCCL**、**RDMA**、**DeepEP**）、GPU 通信（**NVLink**、拓扑优化）、云原生（**Kubernetes**、**Operator**）。
- 熟悉 **GPU 虚拟化**（**MIG**、**vGPU**）与异构混合调度，有生产环境落地经验。
- 熟练使用 **Coding Agent** 工具（**Claude Code**）提升研发效率，有 **AI 辅助代码生成**、文档撰写、问题排查的实践经验。